

Verificacion de Gibbs, Parametro Beta, y Experimentos a Escala

(Notebook: phase3_findings)

Abstract

Este documento cubre tres temas: (1) encontramos y corregimos un bug en el muestreador de Gibbs, (2) exploramos el parametro β que controla cuanto le importa al algoritmo “aprender” vs “aclarar”, y (3) corrimos experimentos preliminares con 20 personas. Los parametros α y las comparaciones con la tesis de Nico estan en el documento 03.

1 El Bug del Gibbs y Como lo Arreglamos

1.1 Que es el Gibbs?

Cuando tenemos muchas personas ($n > 20$), no podemos calcular las probabilidades exactas de infeccion despues de un test. Usamos **muestreo de Gibbs**: un metodo que genera muchas combinaciones posibles de “quien esta infectado” y promedia sobre ellas.

1.2 El problema

Encontramos que Gibbs daba respuestas incorrectas cuando los pools se traslapaban (compartian personas).

Ejemplo: si pool 1 = $\{A, B\}$ y pool 2 = $\{B, C\}$, los resultados de ambos tests restringen juntos quien puede estar infectado. Gibbs no exploraba bien todas las combinaciones validas — se quedaba “atrapado” en una region del espacio.

Antes del fix: 85.8% de tests pasaban. **Despues del fix:** 100% de tests pasaban (64/64).

1.3 La solucion

Dos cambios:

1. Si quedan ≤ 7 personas activas, calcular exacto (no Gibbs).
2. Agregar “movimientos de Metropolis-Hastings”: proponer intercambios globales de infectado/sano entre pares de personas. Esto permite saltar entre regiones desconectadas.

1.4 Verificacion de convergencia

Probamos con distintas cantidades de iteraciones: 50, 100, 200, 500, 1000, 2000, 5000.

- Con ≥ 500 iteraciones, el error maximo cae por debajo de 0.03.
- Con ≥ 2000 , el error es < 0.01 .
- Conclusion: 1000 iteraciones es un buen default.

2 El Parametro Beta (β): Aclarar vs Aprender

2.1 Que es β ?

Cuando el algoritmo greedy elige que grupo testear, normalmente solo le importa una cosa: *aclarar personas* (que el resultado sea $r = 0$).

Su puntaje para cada pool es:

$$\text{score}_{\text{normal}} = P(r = 0) \times \sum u_i$$

Es decir: “la probabilidad de que todos en el pool esten sanos, multiplicada por el valor total de aclarar a esas personas”.

Pero hay otra cosa util: *aprender quien esta infectado*. Aunque $r > 0$ (el pool sale positivo), el numero exacto r nos da informacion valiosa sobre las personas del pool.

β agrega un bonus por informacion:

$$\text{score}_{\beta} = P(r = 0) \times \sum u_i + \beta \times \text{ganancia_de_info}$$

- $\beta = 0$: greedy normal. Solo quiere aclarar.
- $\beta > 0$: tambien valora aprender. Puede elegir pools mas grandes o mas “informativos” aunque tengan menor chance de salir negativos.

Analogia: es como decidir entre una pregunta de examen facil (que sabes que vas a contestar bien) vs una dificil (que te ensena mas para las siguientes preguntas).

2.2 Que mide la “ganancia de informacion”?

Usamos la metrica **confirmed**: cuenta cuantas personas quedarian con probabilidad > 0.95 o < 0.05 despues del test. Es decir, cuantas personas “resolvemos” en terminos de certeza, aunque no las “aclaremos” formalmente.

2.3 Experimento 1: Prevalencia alta ($p \approx 0.8$)

Escenario VIP con $n = 20$, $B = 6$, $G = 10$. Los VIPs tienen $p = 0.8$.

Resultado: β tiene efecto limitado.

Por que? Porque con $p = 0.8$, la probabilidad de que un pool salga negativo es casi cero (0.2^k para un pool de tamano k). El score base es muy bajo, asi que β tiene efecto limitado a valores chicos. Con β grande (2+), la EU puede subir moderadamente y el algoritmo cambia a pools mas grandes, pero la relacion no es monotona.

2.4 Experimento 2: Prevalencia moderada ($p \approx 0.35$)

Escenario VIP similar con $n = 20$, $B = 6$, $G = 5$, VIPs con $p = 0.35$.

Resultado: β tiene efecto moderado.

- $\beta = 0$: pools chicos, EU base.
- $\beta = 2$: pools mas grandes, mejor EU entre los valores probados.
- $\beta = 1$: no necesariamente mejor que $\beta = 0$ — la relacion no es monotona.

Prevalencia	Efecto de β	Recomendacion
Baja ($p < 0.1$)	No probado	Probablemente innecesario (pools ya funcionan bien)
Moderada ($p \approx 0.2\text{--}0.4$)	Moderado	Probar $\beta \in [1, 3]$
Alta ($p > 0.5$)	Limitado	β no ayuda mucho

Table 1: Cuando usar β .

2.5 Resumen de β

3 Experimentos Preliminares a Gran Escala

Corrimos experimentos con $n = 20$, $B = 2$, $G = 10$ (configuracion D). Estos son resultados **preliminares** con 1–2 instancias por configuracion (se necesitan ~ 50 para conclusiones estadisticas).

3.1 Resultados

- El greedy (con Mosek para seleccion de pools) captura $\sim 35\%$ del gap entre U_{single} y U_{max} .
- El gap es grande: con solo $B = 2$ tests para 20 personas, hay mucho margen de mejora.
- Con escenario VIP ($B = 6$): el gap se reduce.
- Con utilidades sesgadas (algunos valen mucho mas): el gap tambien cambia.

Limitacion: estos son quick-runs. Los numeros exactos pueden cambiar con mas instancias.