¿Que tan buena es la heuristica de independencia?

(Notebook: independence_gap_demo)

Abstract

El greedy dinamico usa una formula tipo producto sobre las marginales $\tilde{p}_i$ para estimar cuantos infectados hay en un pool candidato t. Esto asume que los Z_i son independientes dado el historial, lo cual en general NO es cierto. Este documento mide que tan lejos esta esa heuristica de la probabilidad verdadera.

Conclusion corta: la mayoria del tiempo la heuristica acierta (la mitad de los pools tienen error exactamente cero), pero en la cola el error puede ser muy grande (hasta 0.55).

1 ¿Que estamos comparando?

Cada individuo i esta infectado ($Z_i = 1$) o no ($Z_i = 0$). Despues de ver el historial H (lista de pools probados y sus resultados), el greedy mantiene las marginales posteriores

$$\tilde{p}_i = \mathbb{P}(Z_i = 1 \mid H).$$

Para decidir el siguiente pool, el greedy necesita saber cuantos infectados hay en un pool candidato t, es decir la variable aleatoria

$$r_t = |t \cap Z| = \sum_{i \in t} Z_i.$$

El greedy aproxima la distribucion de r_t asumiendo que los Z_i son independientes dado H. Con esa suposicion, r_t tiene una distribucion Poisson-Binomial con parametros $(\tilde{p}_i)_{i \in t}$. En particular:

- $\mathbb{P}(r_t = 0 \mid H) \approx \prod_{i \in t}(1 - \tilde{p}_i)$ (el caso "clear" que usa el score myopico).
- $\mathbb{P}(r_t = |t| \mid H) \approx \prod_{i \in t} \tilde{p}_i$ (el caso "todos infectados", que es la formula que escribe el usuario).

El problema: tests previos introducen dependencias entre los Z_i. Por ejemplo, si antes probamos $t' \subsetneq t$ y t' salio positivo (al menos un infectado), entonces t tambien tiene al menos un infectado con probabilidad 1. Pero la heuristica le sigue dando masa positiva al evento "ningun infectado en t".

2 Ejemplo concreto

Cuatro personas con prior $p_i = 0.5$. Historial: probamos $t' = \{0, 1\}$ y el resultado fue $r' = 1$ (exactamente uno de los dos esta infectado). Ahora miramos el pool $t = \{0, 1, 2, 3\}$.

Como al menos uno de $\{0, 1\}$ esta infectado, se sigue que $r_t \geq 1$ siempre, es decir, $\mathbb{P}(r_t = 0 \mid H) = 0$ exacto.

	$r_t = 0$	$r_t = 1$	$r_t = 2$	$r_t = 3$	$r_t = 4$
Exacta	0.0000	0.2500	0.5000	0.2500	0.0000
Heuristica	0.0625	0.2500	0.3750	0.2500	0.0625

Table 1: Distribucion exacta de r_t vs. la heuristica Poisson-Binomial. El error en los extremos es 0.0625; la distancia de variacion total es 0.125.

Pero las marginales posteriores de 0 y 1 son $\tilde{p}_0 = \tilde{p}_1 = 0.5$ (por simetria), asi que la heuristica da

$$\prod_{i \in t}(1 - \tilde{p}_i) = 0.5 \cdot 0.5 \cdot 0.5 \cdot 0.5 = 0.0625.$$

Interesante: las marginales son correctas (cada $\tilde{p}_i$ es exacto), pero la forma de la distribucion esta mal porque los Z_i no son independientes una vez vista la historia.

3 ¿Que tan frecuente es esto?

Generamos 300 instancias aleatorias con $n = 8$ personas, priors uniformes en $[0.05, 0.5]$, y 3 tests seleccionados con el greedy myopico. Para cada instancia evaluamos *todos* los pools candidatos de tamano 2 y 3, y comparamos la distribucion exacta (por enumeracion de los 2^n mundos) contra la heuristica Poisson-Binomial.

Medimos tres cosas por pool:

- **TV** (distancia de variacion total): suma de las diferencias absolutas entre las dos PMFs, dividida entre 2. Va de 0 (igual) a 1 (totalmente distinto).
- **Error en "ninguno infectado"**: $\left|\mathbb{P}(r_t = 0 \mid H) - \prod(1 - \tilde{p}_i)\right|$.
- **Error en "todos infectados"**: $\left|\mathbb{P}(r_t = |t| \mid H) - \prod \tilde{p}_i\right|$.

$\|t\|$	n pools	TV media	TV mediana	TV p95	TV max	gap r0 medio	gap rmax medio
2	8400	0.0243	0.0000	0.2166	0.5000	0.0121	0.0121
3	16800	0.0501	0.0000	0.4696	0.5555	0.0238	0.0091

Table 2: Error de la heuristica sobre 300 instancias ($n = 8$, $B = 3$, $G = 3$). La mediana es cero: la mayoria del tiempo la heuristica acierta. Pero el p95 y el max muestran que la cola es gorda.

Lectura:

- En mas de la mitad de los pools, el error es cero: la heuristica acierta. Esto pasa cuando el pool no se traslapa con el historial, o cuando todo el pool ya quedo determinado por los tests previos.
- En el top 5% de los pools (la "cola"), el error llega hasta ~ 0.47 para pools de tamano 3: errores grandes.
- El peor caso (~ 0.55) aparece cuando el historial "amarra" a un subconjunto del pool (como en el ejemplo de arriba) pero deja las marginales individuales intermedias.

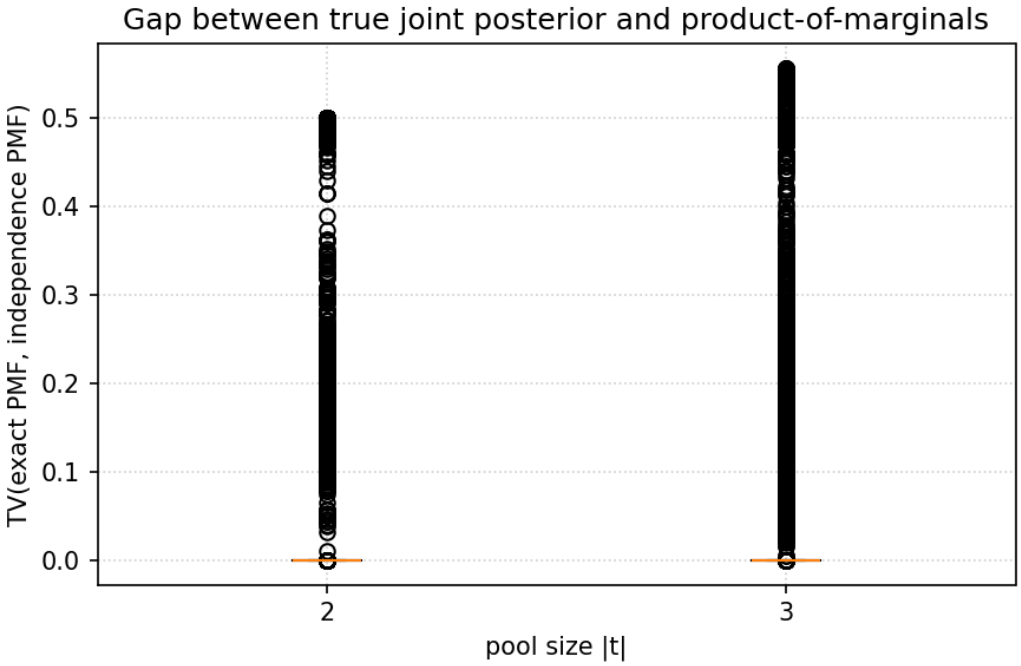

Figure 1: Error entre la PMF exacta y la heuristica, agrupado por tamano del pool. La caja esta pegada a cero: la mayoria de los pools tiene error muy pequeno. Los puntos sueltos arriba son casos raros donde el error llega casi a 0.55.

4 ¿Cuando falla la heuristica?

Los 5 peores casos del experimento comparten el mismo patron: $\mathbb{P}(r_t = 0 \mid H) = 0$ exactamente (el historial garantiza al menos un infectado en t), pero la heuristica da masa entre 0.03 y 0.30 ahi. Ese error se "contagia" al resto de la PMF porque los $\tilde{p}_i$ son correctos pero ignoran la correlacion.

En concreto, el error de la heuristica aumenta cuando:

1. Hay un $t' \subsetneq t$ en la historia con $0 < r' < |t'|$ (resultado intermedio: amarra a los miembros sin determinarlos).

2. Varios pools del historial se traslapan con t (mas restricciones conjuntas no capturadas por las marginales).

3. El tamano del pool candidato es mayor (mas productos de marginales que acumulan el error).

Cuando la historia *si* determina a todos los miembros del pool (por ejemplo, un test con $r' = 0$ o $r' = |t'|$ sobre todo el pool), las $\tilde{p}_i$ son 0 o 1 y la heuristica recupera exactamente la distribucion verdadera. Cuando la historia no toca al pool, tambien coinciden. Esos dos casos dominan la muestra y por eso la mediana del error es cero. El problema aparece en el medio: cuando la historia amarra a *algunos* miembros sin determinarlos.

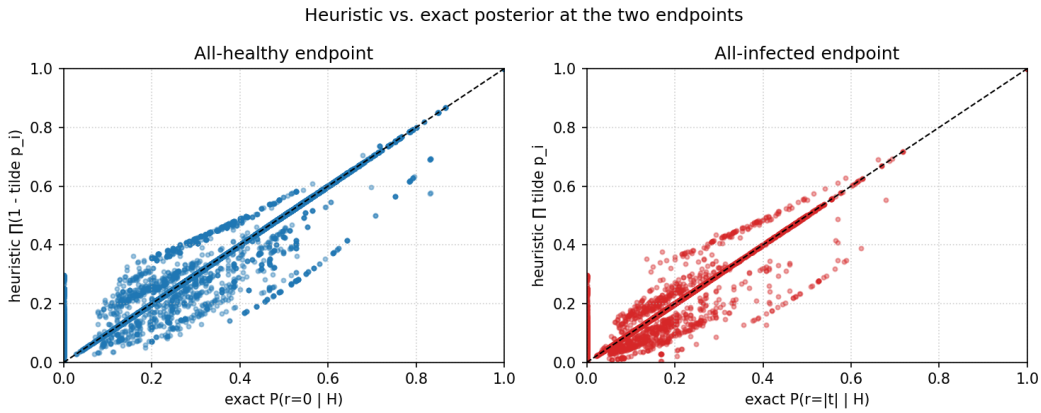

Figure 2: Cada punto es un pool. A la izquierda comparamos la probabilidad de "ninguno infectado": eje x la exacta, eje y la heuristica. A la derecha, "todos infectados". La linea punteada es la diagonal (heuristica = exacta). La mayoria cae sobre la diagonal, pero hay una nube sobre la diagonal a la izquierda: la heuristica a veces dice que el pool puede "limpiar" cuando en realidad el historial ya excluye ese evento.

5 Implicaciones para el greedy

El score myopico es

$$\text{score}(t) = \mathbb{P}(r_t = 0 \mid H) \cdot \sum_{i \in t} u_i,$$

pero se computa con la heuristica $\prod_{i \in t}(1 - \tilde{p}_i)$. Cuando esa probabilidad heuristica esta sobreestimada (como en los peores casos aqui), el greedy puede preferir pools que en realidad NUNCA van a "limpiar" nada.

Una direccion razonable es:

- Reemplazar $\prod(1 - \tilde{p}_i)$ por la probabilidad exacta $\mathbb{P}(r_t = 0 \mid H)$, calculada directamente sobre la distribucion conjunta (por ejemplo, con el counting ya implementado o una consulta conjunta via Gibbs).
- Medir si esa correccion reduce la brecha contra el optimo, usando los mismos experimentos de phase3/sprint3.

6 Como reproducir

```
python augmented/independence_gap_demo.py
```

Los tests unitarios estan en `augmented/tests.py` (prefijos `test_exact_pool_pmf_...`, `test_deterministic_s` etc.) y la logica esta en `augmented/independence_gap.py`.