

Formulacion PWT: super-nodos y restriccion de W

(Notebook: 06_pwt)

Abstract

Una propuesta PWT re-formula el problema de “elegir el siguiente pool” en Greedy Dynamic, agregando un super-nodo w_T por cada subconjunto T de la poblacion ya cubierta S . Si existe una α -aproximacion para el problema de un solo paso (PWT), componiendola debiera dar una garantia $(1 - e^{-\alpha})$ para Greedy Dynamic.

Resumen: la formulacion escalar (peso, prob, util) reproduce exacto al greedy myopic con la lectura “all-clear”, pero *no* cierra el lookahead gap, porque es ciega a la PMF de conteo. Resolvemos empiricamente el problema de complejidad: la heuristica **partner** permite reducir W de tamaño $2^{|S|}$ a un top- L con $L \approx 1-3$ en promedio en seis regimenes diversos. Lo que queda abierto: probar submodularidad adaptativa de $g_h(T, U)$ con observacion de conteo.

1 Setup

Poblacion N , presupuesto B , tamaño maximo de pool G , prior $p \in [0, 1]^N$, utilidad $u(F, Z) = \sum_i \text{proven healthy } u_i$. El test es *augmentado*: $r(t, Z) = |t \cap Z|$, el conteo exacto.

Despues de k pruebas con pools $t_1, \dots, t_k$, sea $S = \bigcup_j t_j$ y $V = N \setminus S$. La formulacion PWT agrega super-nodos $W = \{w_T : T \subseteq S, T \neq \emptyset\}$ con

$$\text{peso}(w_T) = |T|, \quad \text{prob}(w_T) = \prod_{i \in T} (1 - p_i), \quad \text{util}(w_T) = \sum_{i \in T} u_i.$$

PWT (problema de un paso): elegir $t \subseteq V \cup W$ con $\sum \text{pesos} \leq G$ y $|t \cap W| \leq 1$, maximizando la utilidad esperada.

Algoritmo: para cada $w_T \in W$ (incluyendo el caso “ningun super-nodo”), resolver/aproximar el sub-problema y quedarse con el mejor.

2 Formulacion escalar es exacta para myopic

Claim. La formulacion PWT con $\text{prob}(w_T) = \prod (1 - p_i)$ reproduce *exactamente* el valor de greedy myopic.

Por que. El score myopic estandar de un pool t es

$$(\sum_{i \in t} u_i) \cdot \prod_{i \in t} (1 - p_i).$$

Particionando $t = U \cup T$ con $U \subseteq V$ y $T \subseteq S$:

$$(\sum_{i \in U} u_i + \sum_{i \in T} u_i) \cdot \prod_{i \in U} (1 - p_i) \cdot \prod_{i \in T} (1 - p_i) = (\text{util}_U + \text{util}_T) \cdot \text{prob}_U \cdot \text{prob}_T.$$

Sumativo en utilidades, multiplicativo en probabilidades. Los factores de T entran exactamente como los de U .

Verificado empíricamente sobre $n = 6$, $G = 3$, $B = 2$ con prior y posterior arbitrarios: el pool elegido y el valor coinciden bit-a-bit con la enumeración completa.

Lectura alternativa (OR-event). Codex propuso $\text{prob}(w_T) = 1 - \prod(1 - p_i)$ — esto resuelve un *objetivo distinto* y elige peor pool. Es la lectura que rompe; la lectura all-clear es la correcta.

3 Defecto: dos T con mismo escalar pero distinto valor de info

Aunque la formulación escalar es exacta para el paso myopic, es *ciega a la PMF de conteo*. Esto importa cuando hay lookahead.

Construcción. $T_1 = \{a\}$ con $p_a = 0.5$, y $T_2 = \{b, c\}$ con $p_b = p_c = 1 - 1/\sqrt{2} \approx 0.293$. Tienen idénticos:

- OR-prob: $\Pr(Z \cap T \neq \emptyset) = 0.5$
- All-clear prob: $\prod(1 - p_i) = 0.5$
- util si $u_a = u_b + u_c$

Pero la PMF del conteo r difiere:

$$\Pr_{T_1}(r) = (0.50, 0.50), \quad \Pr_{T_2}(r) = (0.50, 0.41, 0.09).$$

La entropía de Shannon: $H(r_{T_1}) = 1.00$ bits, $H(r_{T_2}) = 1.33$ bits. T_2 acarrea estrictamente más información sobre Z .

Implicación. Cualquier algoritmo de un paso que use solo el escalar ($|T|$, prob, util) trata a T_1 y T_2 idéntico, pero un paso con lookahead que actualice por el resultado $r > 0$ los va a distinguir. Por lo tanto la formulación escalar de PWT *no* cierra el lookahead gap.

4 El lookahead gap crece con B

Para la instancia $n = 6$, $G = 3$, p y u fijos:

B	greedy(true)	DP optimum	gap
2	18.4414	18.5817	+0.1403
3	20.4740	22.4339	+1.9598

Table 1: Lookahead gap en función del presupuesto. greedy(true) se obtiene simulando la política greedy sobre cada z y promediando.

PWT escalar reproduce exacto a greedy myopic, así que vive en la columna “greedy(true)”. **No reduce el gap.**

5 Q3: restringir W a top- L

$|W| = 2^{|S|} - 1$ es exponencial. Para hacer la enumeración práctica queremos quedarnos con un top- L por una heurística barata. Definimos $L_{\min}$ = el menor L tal que el top- L contiene al T^* óptimo.

Heurísticas probadas.

- **self:** $(\sum u_T) \cdot \prod(1 - p_T)$ — valor del pool = T solo.

- **prob**: $\prod(1 - p_T)$.
- **util**: $\sum u_T$.
- **ent_λ**: **self**(T) + $\lambda \cdot H(r_T)$ — aumentado con entropia.
- **partner**: $(\sum u_T + u^*) \cdot \prod(1 - p_T) \cdot p^*$ donde (u^*, p^*) es la utilidad/prob del *globalmente mejor pool de V de tamaño G - |T|*, precomputado.

Resultado del sweep (K=20 trials por regimen, $|W|$ es el mean, format mean/max):

Regimen	$ W $	partner	self	prob
baseline ($n = 10$, $G = 4$, p baja)	79.7	1.6 /13	4.3/21	16.1/98
prevalencia alta ($p \sim U[.4, .7]$)	79.7	2.8/14	0.7 /2	4.8/42
n grande ($n = 15$, $G = 5$)	278.3	1.1 /4	12.7/132	38.3/233
historia profunda (3 pasos)	62.9	1.1 /3	3.8/18	14.1/40
prevalencia bimodal	79.7	1.0 /1	8.4/35	22.5/86
utilidad outlier ($u_0 = 50$)	79.7	1.4 /12	2.4/13	12.8/82

Table 2: $L_{\min}$ por regimen. **partner** domina en 4 de 6 regimenes y se mantiene ≤ 3 en mean siempre. Importante: para $n = 15$ con $|W| = 278$, mean $L_{\min}$ se mantiene en 1.1 — no escala con $|S|$.

Por que partner funciona. Es esencialmente una cota inferior sobre $\text{val}(T)$ usando como sucedaneo el mejor pool global de V . Es ajustada cuando ese mejor pool no cambia mucho con el tamaño de T — lo cual ocurre en la mayoría de los regimenes. Crucialmente, *toma en cuenta el budget consumido por T*, cosa que **self** ignora.

Entropia no ayuda. **ent_λ** con $\lambda > 0$ empata o empeora a **self**. Razon: T 's con alta entropia son tipicamente T 's grandes con probabilidades intermedias, que son malos pools myopicos. La informacion de pasos futuros no es la señal correcta para rankear el paso myopic.

6 Caso adversarial

Construimos $S = \{0, 1, 2, 3\}$, $V = \{4, 5\}$, $G = 4$, $p = (.01, .01, .60, .05, .05, .50)$, $u = (1, 1, 100, 50, 60, 80)$.

Pool optimo: $\{3, 4\}$ con $\text{val} = 99.27$. $T^* = \{3\}$ (singleton). **self** rankea $\{2, 3\}$ arriba porque $\text{util}_T = 150$ domina pese a $\text{prob}_T = 0.4$. Pero $\text{val}(\{2, 3\}) = 75.81$ — el factor 0.4 multiplica con el factor de V y hunde el conjunto.

Heuristica	$L_{\min}$	Fraccion de $ W $
partner	2	13.3%
prob	4	26.7%
ent_1	8	53.3%
self	8	53.3%
util	12	80.0%
rand	15	100.0%

Table 3: Adversarial worst-case. $|W| = 15$. **partner** mantiene $L_{\min}$ chico (top-2), **self** requiere bajar a la posicion 8 de 15 — 53% de la lista.

7 Conclusiones y trabajo abierto

Lo que la formulacion PWT da:

1. Equivalencia myopic exacta con la lectura all-clear. El escalar $(|T|, \prod(1-p), \sum u)$ basta para reproducir la decision myopic.
2. Restriccion practica: la heuristica **partner** reduce $|W| = 2^{|S|}$ a top- L con $L \sim 1-3$ en promedio en $n = 15$ con $|W| = 278$.

Lo que falta:

1. **Cota worst-case sobre $L_{\min}$ con partner.** Empiricamente $\max L_{\min} \leq 14$ en todos los regimenes, pero no hay prueba teorica ni adversarial conocido.
2. **Submodularidad adaptativa de $g_h(T, U)$ con observacion de conteo.** Sin esta, una α -aproximacion por paso *no* compone a una garantia global $(1 - e^{-\alpha})$. Esta es la pregunta Q4 en docs/notes/pwt_submodularity.md.
3. **Ranking lookahead-aware.** La entropia simple no funciona, pero un ranking que use la *ganancia esperada de informacion* podria preservar garantias multi-paso.

Veredicto practico. PWT con **partner** y $L = 5$ es una implementacion valida del paso de Greedy Dynamic, equivalente al greedy actual pero mas modular para analisis teorico. **Veredicto teorico.** Sin Q4, la formulacion es una re-organizacion limpia, no una reduccion garantizada.