

Notebook 07 — Variant of Greedy y primeras pruebas de RL

Estamos en la ronda k del algoritmo greedy. Ya se hicieron las pruebas $t_1, \dots, t_k$ y escribimos $N_k = \bigcup_{i=1}^k t_i$. Para cada $A \subseteq N_k$ definimos

$$\bar{q}_A = \Pr[A \text{ negativo} \mid \text{resultados actuales}],$$

y construimos una instancia ampliada $R = ([n] \setminus N_k) \cup \{A \subseteq N_k\}$, donde cada super-nodo A lleva utilidad $u_A = \sum_{i \in A} u_i$.

Una aclaración importante. En las figuras de este notebook usamos la versión *factorizada*


$$\tilde{q}_A = \prod_{i \in A} (1 - p_i^{\text{post}}),$$

es decir, tratamos los posteriores marginales como si fueran independientes. La probabilidad conjunta exacta $\bar{q}_A$ puede diferir tras una prueba con conteo positivo, porque entonces los individuos del pool quedan correlacionados. Lo señalamos donde sea relevante.

Este documento explica las cuatro figuras del notebook `07_vw.ipynb`: dos sobre la idea de super-nodos (VW) y dos sobre las primeras pruebas de reinforcement learning.

Parte 1 — La idea de super-nodos (VW)


Figura 1 — VW all-clear y el greedy miópe



Instancia de juguete con $n = 6$, $G = 3$. Aquí no resolvemos todavía toda la instancia ampliada R : hacemos una prueba local. Para cada pool candidato comparamos su score míope (eje x : utilidad por probabilidad factorizada de salir limpio) contra el score que induce la lectura VW (eje y). Con la lectura **all-clear** ($\tilde{q}_A = \prod_{i \in A} (1 - p_i)$, en verde) todos los puntos caen sobre la diagonal: bajo esta lectura factorizada, VW all-clear produce *exactamente el mismo ranking de pools* que el greedy míope. Con la lectura **or-event** ($1 - \prod (1 - p_i)$, en rojo) los puntos se dispersan: es otro objetivo y elige pools distintos.

Pregunta para Francisco. *Que VW all-clear coincida exacto con el paso míope: ¿es la noticia que queríamos (el subproblema VW es tan manejable como el míope) o más bien indica que la reformulación aún no añade nada nuevo?*

Figura 2 — la brecha con el óptimo crece con B




Misma instancia de juguete ($n = 6$, $G = 3$). Como la Figura 1 muestra que VW all-clear factorizado coincide con el greedy míope, usamos el greedy como representante de esa versión de VW y lo comparamos contra el óptimo exacto por programación dinámica (DP). Con $B = 2$ la brecha es pequeña ($\approx 0,14$); con $B = 3$ se amplía notablemente ($\approx 1,96$). Cuantas más pruebas quedan, más cuesta ignorar el futuro: VW por sí solo no cierra esa brecha.

Pregunta para Francisco. *La brecha crece de $B = 2$ a $B = 3$: ¿esperarías que se estabilice a partir de cierto B , o que siga creciendo mientras queden pruebas por gastar?*

Parte 2 — Primeras pruebas de Reinforcement Learning

Vemos el problema como un MDP: el estado es (pruebas usadas, configuraciones de infección aún posibles, individuos ya descartados), la acción es el pool elegido y la recompensa final es la utilidad descartada.


Figura 3 — Q-learning se acerca al óptimo del DP



Validación en una instancia pequeña ($n = 4$, $B = 2$, $G = 3$). Q-learning tabular no conoce el modelo: solo juega episodios y actualiza sus estimaciones. Al aumentar los episodios de entrenamiento, la utilidad de su política sube y se acerca al óptimo exacto del DP (línea roja); con presupuesto finito de episodios se estanca un poco por debajo. Esto sirve como validación empírica de que el planteamiento como MDP está alineado con el DP exacto.

Pregunta para Francisco. *Q-learning se acerca al óptimo pero, con un presupuesto finito de episodios, se estanca un poco por debajo. ¿Te interesa más una garantía de convergencia exacta, o una cota de cuántos episodios bastan para quedar a ε del óptimo?*

Figura 4 — el método exacto se estrella al crecer n



Medimos el tiempo de la solución exacta (value iteration sobre los estados de información) para $n = 2, \dots, 9$ con $B = 2$, $G = 3$, y extrapolamos. El crecimiento es exponencial: más allá de $n \approx 14$ el cómputo exacto deja de ser viable. Ahí se vuelve natural considerar métodos aproximados: RL con aproximación de funciones (por ejemplo PPO), poda basada en VW, o heurísticas con lookahead.

Pregunta para Francisco. *El cómputo exacto se estrella en $n = 14$. Antes de saltar a PPO, ¿vale la pena formalizar una poda VW que reduzca el espacio de estados, o prefieres usar esta pared computacional como motivación directa para RL aproximado?*